

耗时来自结构、方法，还是 Agent？

真实轮次完整计时 + 固定证据离线对照 | 可复查的实验报告

25 分 22 秒

原始真实轮次总耗时；其中规划 735.2 秒

10 组对照 / 13 次完成记录的模型调用

固定同一现场、同一组图片、同一模型；无机器人动作。

本报告区分观测结果、因果线索与尚未验证的结论。

先看实验结论

最快结果必须同时通过离线质量检查；不等于真实抓取成功

最快通过离线检查：G 图片直接输入，219.0 秒。

基准 A：488.0 秒；合并 C：418.7 秒（API 重试 1 次）。

同配置复测 C'：226.2 秒；服务与执行波动必须计入解释。

结论限定为一个场景的筛查；不能宣称算法下限或物理精度不变。

原始真实轮次：完整耗时表

各行互不重叠，可相加。 1521.7 秒 = 25 分 22 秒。

阶段	耗时 / 秒	占比
初始拍照与感知	19.2	1.3%
操作前 supervisor	103.3	6.8%
朝向准备与 Molmo	83.7	5.5%
完整规划	735.2	48.3%
机器人执行及录像收尾	98.2	6.5%
操作后拍照	14.0	0.9%
视频证据准备	3.1	0.2%
evaluation	159.2	10.5%
操作后 supervisor	81.9	5.4%
经验更新与保存	223.5	14.7%
其他校验、调度、落盘	0.4	0.0%
合计	1521.7	100%

何时算“这一轮结束”？

同一轮可以有不同的业务终点，不能混用时间口径。

终点	自开始累计	含义
规划完成	约 941 秒	抓取点、目标点和动作已生成
机器人执行结束	约 1040 秒	包含执行与录像收尾
evaluation 完成	约 1216 秒	20 分 16 秒，已有本轮效果判断
整轮正常返回	约 1522 秒	又做了 supervisor 与经验更新

evaluation 之后额外约 305 秒，不能归因于“选点太慢”。

735 秒规划：编辑结束后仍有 502 秒

阶段边界由 Host 计时；不是对私有思考内容的猜测。

子阶段	耗时	实际交付
图像编辑与证据准备	231.8 秒	图片、发现、充分性判断、引用链
只读抓取点选择	261.4 秒	Rxx 抓取点与策略
只读目标及动作规划	241.1 秒	目标像素、动作序列、编译
其他规划开销	0.9 秒	调度与准备

后两次调用均为 0 次编辑；但分别读取上下文 16 次。

这次发现的混杂因素：可用信息 ≠ 实际已读信息

因此增加 I：只内联 A 的实际 Read 返回内容，继续保留两次规划调用。

组别	实际输入变化	观察与解释
A 文件读取	自主选择；没有读 experience_context	基准的实际信息少于全部可用文件
B 全部内联	把此前未读的经验也交给模型	更快，但目标点明显左移，需复核
I 已读内容内联	只预先提供 A 实际读到的文本	更接近隔离上下文读取的交互成本

B 的公开输出引用经验要求扩大搬运距离；这提供解释线索，尚不能单独证明因果。

原始图像编辑： 8 轮交互， 3 次编辑

响应输出窗口包括 thinking、文字与工具参数；并非图片运算耗时。

轮次	公开操作	响应前等待 / 秒	输出窗口 / 秒
1	目录与图片列表	34.3	1.3
2	读取约束、参考状态等	1.8	3.1
3	查看原图和标记图	1.7	3.3
4	查看两张参考图	8.0	29.1
5	原图旋转 90°	8.8	13.9
6	裁剪袖子与已折区域	11.4	6.3
7	读取候选、查看 Rxx 图	11.0	13.8
8	提交 READY 与证据	12.0	40.6

三类原因，分别怎样验证

速度收益只有在任务和质量约束可比时才有意义。

类别	控制变量	主要比较
结构	任务和内容不变，改变交付与调用组织	$A \rightarrow B ; B \rightarrow C$
方法 / 算法	结构固定，改变决策步骤或计算辅助	$C \rightarrow D ; D \rightarrow E$
Agent 执行方式	方法固定，约束输出或消除取图交互	$C \rightarrow F ; C \rightarrow G$
波动控制	同一配置再次运行	$C \rightarrow C'$

另测同模型 low effort ； 未测不同模型或 provider 内部排队。

可比性与质量约束

同一组 9 张图片，按校验值冻结；没有提供上次最终选点答案。

固定模型请求、图片、任务、 schema ；所有调用禁止图像编辑。

前两组 motion 使用本组刚产生的抓取方案，避免泄漏旧答案。

检查 schema 、候选资格、坐标引用链、提拉与释放顺序。

额外用当前图像的近似区域复核袖口、胸前目标与向内方向；未运行 IK 或物理动作。

对照实验：总耗时与交互次数

A/B/I 包含两次调用；其余为一次完整选点与动作输出。

实验	秒	调用	响应轮次	Read / 看图	质量
A 文件上下文 · 两次调用	488.0	2	15	33 / 8	离线检查通过
B 内联上下文 · 两次调用	366.0	2	4	0 / 4	需复核
C 内联上下文 · 合并调用	418.7	1	3	0 / 4	离线检查通过
D 明确决策步骤	285.4	1	4	0 / 4	离线检查通过
E 步骤 + 几何代码	240.4	1	2	0 / 2	离线检查通过
F 简洁输出	228.9	1	2	0 / 2	离线检查通过
G 图片直接输入	219.0	1	1	0 / 0	离线检查通过
C' 合并调用复测	226.2	1	4	0 / 3	离线检查通过
H 同模型 · low effort	93.6	1	2	0 / 2	需复核
I 实际已读内容内联	297.3	2	6	0 / 6	离线检查通过

耗时比较：先观察效果，再讨论归因

条形长度是该组总墙钟时间，包含调用与本地校验。



成对比较：每次只解释对应变化

联合调用对照采用 C'（C 有服务重试）；顺序、缓存和单样本波动仍限制因果结论。

改变	之前 → 之后 / 秒	耗时减少	离线质量：前 → 后
全部上下文交付	488.0 → 366.0	+25.0%	通过 → 复核
合并调用	366.0 → 226.2	+38.2%	复核 → 通过
明确步骤	226.2 → 285.4	-26.2%	通过 → 通过
代码辅助	285.4 → 240.4	+15.8%	通过 → 通过
简洁输出	226.2 → 228.9	-1.2%	通过 → 通过
直接输入图片	226.2 → 219.0	+3.1%	通过 → 通过
同配置波动	418.7 → 226.2	+46.0%	通过 → 通过
推理强度	226.2 → 93.6	+58.6%	通过 → 复核
已读信息匹配	488.0 → 297.3	+39.1%	通过 → 通过

服务异常：需要单独归类的第四种因素

不能把服务端重试造成的长尾全部归因于结构、算法或 Agent。

实验	API 重试次数	记录的错误状态
A 文件上下文 · 两次调用	0	无记录
B 内联上下文 · 两次调用	0	无记录
C 内联上下文 · 合并调用	1	[524]
D 明确决策步骤	0	无记录
E 步骤 + 几何代码	0	无记录
F 简洁输出	0	无记录
G 图片直接输入	0	无记录
C' 合并调用复测	0	无记录
H 同模型 · low effort	0	无记录
I 实际已读内容内联	0	无记录

重试事件的时间戳不等于失败请求时长；不直接扣除 168 秒或将其视为纯网络时间。

Token 不是时间：这里展示 CLI 的记录值

主调用总量含缓存； thinking 已在 output 中。费用含辅助模型。 * 表示 usage 可疑，不能推断推理量。

实验	主调用 token	输出 token	其中 thinking	记录费用 / USD
A	382,031	28,904	20,525	1.375
B	143,716	53,122	45,850	1.886
C	105,903	12,129	8,231	0.729
D*	105,476	4,342	505	0.410
E	103,453	34,892	29,120	1.322
F	87,814	32,488	27,717	1.129
G	57,769	26,419	20,721	0.871
C'	159,886	14,404	6,790	0.714
H	60,134	3,990	1,064	0.327
I	177,730	14,176	9,491	0.864

等待、输出和传输：不能叫作纯思考时间

下表按观测窗口统计；不同列有包含关系，不用于相加得到总耗时。

实验	总墙钟 / 秒	响应前等待合计	响应输出窗口	CLI 窗口
A	488.0	85.6	348.7	451.4
B	366.0	33.4	300.5	336.2
C	418.7	241.3	160.9	403.6
D	285.4	41.7	227.5	270.6
E	240.4	18.2	206.2	225.5
F	228.9	17.8	191.8	210.6
G	219.0	39.8	156.8	207.4
C'	226.2	22.0	190.5	213.5
H	93.6	27.8	46.4	75.5
I	297.3	62.1	181.6	254.6

输出质量：抓取点 G → 目标点 T


黄色为抓取点，青色为目标点；所有结果映射到同一张当前衣服图。




A • R088 • 离线检查通过



B • R088 • 需复核



C • R089 • 离线检查通过



D • R088 • 离线检查通过

输出质量：抓取点 G → 目标点 T


黄色为抓取点，青色为目标点；所有结果映射到同一张当前衣服图。



E • R099 • 离线检查通过



F • R088 • 离线检查通过



G • R088 • 离线检查通过



C' • R089 • 离线检查通过

输出质量：抓取点 G → 目标点 T

黄色为抓取点，青色为目标点；所有结果映射到同一张当前衣服图。




H · R088 · 需复核



I · R088 · 离线检查通过

两个“需复核”，原因完全不同

保留原始区域检查，不把近似边界当作物理真值；以下为图像复核。



H：上胸近领口，距近似 ROI 边界约 2px；几何上合理，放置效果待验证。

B：明显落到另一侧已折袖子区域；不能当作质量不变的加速。

另一个结构性问题： CLI 启动时输入未就绪

失败尝试单独保留，不把“30.9 秒退出”当成加速。

I 首次启动报：3 秒内没有收到 stdin；未得到模型响应或 token 终值。

在测试传输中先完整缓存文本，再以 stream-json 启动 CLI。

重跑前核对：提示词和 schema 与失败时完全一致。

这修正的是实验输入交付；没有修改生产规划策略。失败记录仍可复查。

能确认什么，尚不能确认什么

区分软件问题、方法收益与服务行为，避免过度归因。

层面	这次能验证	这次不能证明
结构	减少 Read 和调用是否改善本场景耗时	其他场景也稳定加速
方法	明确步骤 / 几何辅助的输出和耗时变化	现有算法已最优，或耗时是理论下限
Agent	输出约束 / 取图方式的行为差异	全部差异来自模型纯推理或服务排队
质量	离线契约、引用链、语义区域一致性	真实抓取成功率与物理折叠精度

回答最初的三个问题

百分比表示耗时减少；负数表示变慢。各项只针对当前样本。

问题	实验结果	解释边界
结构 / 信息交付	A → I： +39.1% ； 离线检查通过	更接近隔离文件读取的多轮交互成本
方法 / 算法	D → E 减少 +15.8% ； 相对 C'： -6.3%	有局部收益，不等于优于基本联合规划
Agent 执行设置	C' → H： +58.6% ； 需复核	同模型请求 low effort ； 不能外推稳定精度
服务异常	C： 418.7s / C'： 226.2s	C 有 524 重试；这是必须单列的因素

三类原因可以并存；本实验不会把剩余时间自动归给“算法必需”或“Agent 天性”。

建议：按验证结果逐步落地

本次实验没有修改生产推理策略、没有更新正式 skill。

先保留“原始计时 + 公共工具记录 + token”的统一观测口径。

优先复测最快且通过离线检查的配置；再扩展不同朝向与遮挡场景。

若收益大于同配置波动，再单独接入生产流程；保留原流程回退。

上线前追加静态编译 / IK 检查和受控机器人验证，不能直接由速度决定。

复查入口与实验限制

所有数值来自本地记录；原始请求、输出、工具轨迹和 token 均保留。

原始真实轮次

results/two_stage_iteration_timing_20261005_172835/

离线对照与统计

results/latency_ablation_20261005/

复现实验

scripts/benchmark_planner_latency.py

报告生成

scripts/report_planner_latency.py